

Dana jest zależność:

$$Y = \alpha_0 + \alpha_1 X_1 + \alpha_2 X_2 + \dots + \alpha_k X_k + \varepsilon,$$

Estymujemy parametry takiego modelu. Otrzymujemy

$$Y = a_0 + a_1 X_1 + a_2 X_2 + \dots + a_k X_k + \varepsilon, \quad (*)$$

• **WSPÓŁCZYNNIK KORELACJI LINIOWEJ PEARSONA**

Miara statystyczna objaśniająca poziom oraz kierunek zależności liniowej pomiędzy zmiennymi – Czy kolejne realizacje dwóch zmiennych (kolejne obserwacje) odchylają się w stosunku do swoich średnich w tą samą stronę (znak +), w przeciwną (znak -), czy niezależnie (0).

$$r_{XY} = \frac{\sum_{i=1}^N (x_i - \bar{x}) \cdot (y_i - \bar{y})}{S_X \cdot S_Y}$$

Uwaga: Przy budowie modelu ekonometrycznego można dobierać zmienne wg wartości wsp. korelacji pomiędzy zmienną X oraz Y . Wskaźnik $r_{XY} = 0$ sugeruje zupełny brak związku liniowego pomiędzy zmiennymi, wartości bliskie -1 lub 1 wskazują natomiast na możliwość opisu zmienności Y prawie w 100%.

Uwaga 2. Model jest *koïncydentny*, jeśli $\text{sgn } r_i = \text{sgn } a_i$

• **PARA KORELACYJNA, REGULARNA PARA KORELACYJNA**

$$R_0 = \begin{bmatrix} r_1 \\ \dots \\ r_k \end{bmatrix}, \quad R = \begin{bmatrix} 1 & r_{12} & \dots & r_{1k} \\ r_{21} & 1 & \dots & r_{2k} \\ \dots & \dots & \dots & \dots \\ r_{k1} & r_{k2} & \dots & 1 \end{bmatrix}.$$

r_{ji} – współczynnik korelacji pomiędzy X_i i X_j

r_i – współczynnik korelacji pomiędzy X_i i Y

(R, R_0) – **para korelacyjna**

Jeżeli spełniony jest warunek: $0 < r_1 < r_2 < \dots < r_k$,

(R, R_0) – **regularna para korelacyjna**,

UWAGA – jeżeli współczynnik $r_i < 0$, to należy zmienną X_i w modelu podmienić przez zmienną $X_i' = -X_i$.

• **WARIANCJA SKŁADNIKA LOSOWEGO, BŁĘDY SZACUNKU PARAMETRÓW**

Ponieważ parametry modelu estymowane są jedynie na podstawie próby, a nie całej populacji, oraz dane wejściowe są zmiennymi losowymi (zauważ, że obserwowany y składa się m.in. ze składnika losowego ε , a więc zależy od zm. losowej, a więc y jest zm. losową), to parametry również są zmiennymi losowymi.

Nieobciążony i zgodny estymator wariancji σ^2 składnika losowego w modelu (*) szacowanym MNK jest:

$$S^2 = \frac{e^T e}{n - (k+1)} = \frac{(y - Xa)^T (y - Xa)}{n - (k+1)} = \frac{y^T y - a^T X^T y}{n - (k+1)},$$

Nieobciążony i zgodny estymator macierzy kowariancji estymatora a :

$$\hat{D}^2(a) = [d_{ij}] = S^2 (X^T X)^{-1}.$$

Obliczając wartości elementów diagonalnych d_{jj} macierzy $D^2(a)$ otrzymujemy oceny wariancji estymatorów poszczególnych parametrów modelu (*).

$$S_{a_j} = \sqrt{d_{jj}} \quad - \text{średni błąd szacunku parametru } \alpha_j.$$

$$\left| \frac{S_{a_j}}{a_j} \right| \cdot 100\% \quad - \text{średni względny błąd szacunku parametru } \alpha_j.$$

• **WSPÓŁCZYNNIK DETERMINACJI R^2 ($R^2 \in [0,1]$)**

Po zbudowaniu modelu współczynnik determinacji pozwala zmierzyć, w jakim stopniu model umożliwia objaśnienie zmienności zmiennej Y .

Współczynnik determinacji zwykły

- W modelu musi występować wyraz wolny
- Interpretacja jest poprawna pod warunkiem, że badane związki są liniowe.
- R^2 przyjmuje wartości z przedziału $(0, 1)$

$$R^2 = 1 - \frac{\sum_{t=1}^n (y_t - \hat{y}_t)^2}{\sum_{t=1}^n (y_t - \bar{y})^2} = 1 - \frac{(\mathbf{y} - \hat{\mathbf{y}})^T (\mathbf{y} - \hat{\mathbf{y}})}{(\mathbf{y} - \mathbf{1} \cdot \bar{y})^T (\mathbf{y} - \mathbf{1} \cdot \bar{y})} = 1 - \frac{\mathbf{e}^T \mathbf{e}}{\mathbf{y}^T \mathbf{y} - n \cdot \bar{y}^2} = 1 - \frac{\mathbf{y}^T \mathbf{y} - \mathbf{a}^T \mathbf{X}^T \mathbf{y}}{\mathbf{y}^T \mathbf{y} - n \cdot \bar{y}^2}$$

Ponieważ $\varphi^2 = \frac{\sum_{t=1}^n (y_t - \hat{y}_t)^2}{\sum_{t=1}^n (y_t - \bar{y})^2}$ jest to stosunek sumy kwadratów odchyłeń

wartości obserwowanych y_t od teoretycznych \hat{y}_t do sumy kwadratów odchyłeń

obserwowanych y_t od średniej \bar{y} , to φ^2 (**współczynnik indeterminacji**)

podaje, jaki procent zmienności y nie jest objaśniony przez model,

natomiast R^2 (czyli $1 - \varphi^2$) podaje, jaki % zmienności y jest objaśniany przez model.

Inny sposób liczenia takiego współczynnika determinacji:

$$R^2 = R_0^T R^{-1} R_0$$

Współczynnik determinacji skorygowany

Gdy liczba szacowanych parametrów jest niewiele mniejsza od liczby dostępnych obserwacji, to współczynnik determinacji może być zawyżony (zafałszowany względem rzeczywistej jego interpretacji) i wtedy stosujemy

skorygowany współczynnik determinacji $\overline{R^2}$, który jest mniejszy od R^2 ,

$$\overline{R^2} \leq R^2: \quad \overline{R^2} = R^2 - \frac{k}{n - (k + 1)} (1 - R^2)$$

Współczynnik determinacji niescentrowany

Gdy szacowany model jest bez wyrazu wolnego, wtedy stosuje się

niescentrowny współczynnik determinacji $R_N^2 \in [0,1]$:

$$R_N^2 = 1 - \frac{\mathbf{e}^T \mathbf{e}}{\mathbf{y}^T \mathbf{y}}$$

• **EFEKT KATALIZY**

Współczynnik determinacji jest miarą dopasowania modelu ekonometrycznego do danych empirycznych, lecz informacja, jaką niesie o modelu, może być fałszywa, jeśli w modelu występują zmienne, które nazywamy **katalizatorami**.

ZAŁOŻENIE: (R, R_0) - regularna para korelacyjna.

Zmienna X_j z pary zmiennych (X_i, X_j) , $i < j$, jest katalizatorem jeżeli

$$r_{ij} < 0 \quad \text{lub} \quad r_{ij} > \frac{r_i}{r_j}$$

$$\eta = R^2 - H \quad - \text{natężenie efektu katalizy,}$$

Gdzie H jest integralną pojemnością informacyjną zestawu zmiennych objaśniających modelu.

$$W_\eta = \frac{\eta}{R^2} \cdot 100\% \quad - \text{względne natężenie efektu katalizy}$$

Zadanie 1

Dla 20 typów radioodbiorników oszacowano zależność ceny radioodbiornika od cech charakteryzujących jakość. Oszacowano model liniowy postaci:

$$\hat{y}_t = -1636 + 314x_t + 449z_t + 364w_t,$$

w którym:

y_t - cena radioodbiornika typu t , $t = 1, 2, \dots, 20$

x_t - liczba zakresów fal, $x_t \in \{2, 3, 4\}$

z_t - liczba lamp, $z_t \in \{3, 4, 5, 6\}$

w_t - rodzaj skrzynki, $w_t \in \{0, 1\}$, $w_t = 1$ gdy skrzynka drewniana, $w_t = 0$ gdy skrzynka z tworzywa sztucznego.

Podać interpretację parametrów

Zadanie 2

Dla pewnego zakładu oszacowano model

$$\hat{y}_t = 1,65 + 0,45x_t + 0,75z_t - 0,38p_t, t = 1, 2, \dots, 348,$$

w którym:

$x_t = 0$ gdy staż pracy krótszy niż 3 lata,

$x_t = 1$ gdy staż pracy 3 lata lub dłuższy,

$z_t = 0$ wykształcenie podstawowe,

$z_t = 1$ wykształcenie średnie,

$p_t = 0$ mężczyzna,

$p_t = 1$ kobieta,

Porównać zarobki w 3 dowolnych klasach pracowników, jeśli klasą nazywamy grupę pracowników o jednakowym stażu, wykształceniu i płci. Na przykład w klasie $(0, 0, 0)$ są mężczyźni o stażu krótszym niż 3 lata i wykształceniu podstawowym.

Zadanie 3

Czy podana para jest parą korelacyjną? Czy jest regularną parą korelacyjną?

$$R_0 = \begin{bmatrix} -0,01 \\ 0,9 \\ 0,68 \end{bmatrix}, \quad R = \begin{bmatrix} 1 & -0,09 & 0,47 \\ -0,09 & 1 & -0,65 \\ 0,47 & -0,65 & 1 \end{bmatrix}.$$

Zadanie 4

Podczas szacowania MNK parametrów modelu ekonometrycznego postaci

$$y_t = \beta_0 + \beta_1 X_{1t} + \beta_2 X_{2t} + \varepsilon_t, \text{ otrzymano następujące wyniki obliczeń:}$$

$$(X^T X)^{-1} = \begin{bmatrix} 0,125 & 0 & 0 \\ 0 & 0,6 & 0,2 \\ 0 & 0,2 & 0,4 \end{bmatrix}, \quad X^T y = \begin{bmatrix} 12 \\ 4 \\ 5 \end{bmatrix}, \quad y^T y = 60.$$

Podać oszacowania parametrów tego modelu. Wyznaczyć średnie błędy szacunku i średnie względne błędy szacunku. Obliczyć i zinterpretować wartość współczynnika determinacji.

Zadanie 5

Obserwowano kształtowanie się przyrostów popytu na masło (Δy_t), przyrostów cen margaryny (Δx_{1t}) i przyrostów cen masła (Δx_{2t}) w 10 kolejnych okresach. Zebrano następujące dane:

t	1	2	3	4	5	6	7	8	9	10
Δy_t	1	2	3	0	-5	-4	-4	0	1	2
Δx_{1t}	0	0	0	0	0	0	0	1	1	1
Δx_{2t}	-1	-1	-1	0	1	1	1	1	0	0

Założono, że popyt na masło zależy w sposób liniowy od cen masła i cen margaryny. Zbudować liniowy model ekonometryczny objaśniający kształtowanie się zmian popytu na masło w zależności od zmian cen masła i margaryny. Przeprowadzić dyskusję dotyczącą uwzględnienia wyrazu wolnego w konstruowanym modelu. Oszacować parametry wyspecyfikowanego modelu i zinterpretować otrzymane wyniki. Ocenić dopasowanie modelu do danych empirycznych. Czy model jest koincydentny?

Zadanie 6

Dla pewnego liniowego modelu z wyrazem wolnym ($n=8$) dane są:

$$R = \begin{bmatrix} 1 & 0,5 \\ 0,5 & 1 \end{bmatrix}, R_0 = \begin{bmatrix} 0,4 \\ 0,9 \end{bmatrix},$$

$$\sum_t (y_t - \hat{y}_t)^2 = 0,56, \sum_t (y_t - \bar{y})^2 = 3,$$

Czy dane te nie są sprzeczne??